Giriş

Herkese Merhaba, size modeller üzerinde yaptığım testler ve sonuçlarından bahsedicem.

Üzerinde oynanmış girdilerle bu testleri gerçekleştirdim.

Girdileri DistilBERT, RoBERTa ve ALBERT modellerinin sınıflandırma için SST-2 veri setiyle eğitilmiş sınıflandırma kafalarını kullanarak test ettim.

01

İlk olarak Truncation Körlüğü var.

Transformer modelleri sabit bir maksimum sekans uzunluğuna (örneğin 512 token) sahiptir. Girdi boyutlarını modelin sınırlarına uygun hale getirmek için Tokenizer seviyesinde kırpma (truncation) işlemi uygularız. Ancak bu ön işlem doğru stratejiyle yapılmazsa, model ciddi bir bağlam kaybına (context loss) uğrar ve hatalı çıktılar üretir.

Bunu test etmek için pozitif başlayıp sonradan ağır negatife dönen uzun bir film eleştirisi hazırladık. Metnin başlangıcında "Oyunculuklar ve müzikler harikaydı, beklentim çok yüksekti" denirken; devamında "Berbat senaryo", "film tam bir çöptü" gibi ifadeler yer alıyor. Metni tam haliyle modellere verdiğimizde üçü de ortalama olarak %99.98 olasılıkla negatif çıktısı veriyor. Ancak tokenizer'ın truncation parametresini True ve max_length=21 kısıtı koyduğumuzda ki bunu yapsak modele gerçek sınırlarını aşacak upuzun bir girdi vermemiz gerekirdi; modeller metnin sadece ilk pozitif cümlesini görebiliyor ve olumsuz kısmını göremeyip %99.91 olsalıkla Pozitif kararı veriyor.

Üretim ortamında bu tip uzun metinlerde bağlam kaybını önlemek için:

Sliding Window yaklaşımıyla metni parçalar halinde modele verebilir ve çıktıları birlikte değerlendirebiliriz. Ya da metin sınıflandırma kafasına girmeden önce bir özetleme modeliyle (Summarization) model sınırlarına indirgeyebiliriz.

02

Evet, Tokenizasyon Hassasiyeti ve Alt Kelime Kırılmasına Bakalım. Burada tokenizer'ların yazım hatası veya sansürle karşılaştıklarında kelimeyi tanıyamayıp anlamsız parçalara böldüğünde model çıktılarının ne şekilde etkilendiğini göreceğiz.

İki farklı senaryomuz var.

İlk senaryoda girdimiz bir yazım hatası barındırırken ikinci senaryomuzda girdideki olumsuz ifadeler yıldız karakteriyle sansürlendi.

İlk senaryoya baktığımızda "oyunculuk amatörce" ifadesini modellerimize verdiğimizde üçü de ortalama olarak %99.98 olasılıkla Negatif çıktı veriyor. Bu girdideki "amatörce" kelimesinde yalnızca bir harfi yanlış yazdığımızda çıktılar şu şekilde değişiyor. DistilBERT ve ALBERT modelleri tamamen taraf değiştirirken RoBERTa modeli %20 güven kaybı yaşıyor.

İkinci senaryoda "Film berbattı. Nefret ettim." ifadesini modellerimize verdiğimizde sansürsüz girdi için ortalama olarak %99.75 olasılıkla Negatif çıktı alıyoruz. Bu girdideki "terrible" ve "hated" olumsuzluk ifadelerini yıldız karakteriyle sansürlediğimizde çıtktılar şu şekilde değişiyor. DistilBERT modeli yaklaşık %40 güven kaybı yaşarken ALBERT fazla etkilenmiyor. RoBERTa ise sınıf değiştiriyor.

02.0

Burada da ilk senaryomuz için farklı tokenizasyon yaklaşımlarının girdiyi ne şekilde parçaladığını görüyoruz. Yazım hatası içermeyen temiz girdide "amateur" ve "ish" olarak iki token ile ifade edilmiş. Fakat, yazım hatası içeren girdideki "amateirish" kelimesinin ikiden daha fazla token'a bölündüğünü görüyoruz. Burada özellikle SentencePiece kütüphanesinin kullandığı yaklaşımda girdi tokenlerine ayrılırken "amateirish" kelimesini istatistiksel olarak en anlamlı parçalara böler. Burada "mate" ve "irish" kelimeleri hiç bir olumsuzluk ifade etmez. Burada ALBERT modelinin neden pozitif çıktı verdiğini görüyoruz.

02.1

Şimdi ikinci senaryomuzdaki girdinin token'larını inceleyelim. Burada da normalde tek bir token ile ifade edilebilen "terrible" ve "hated" kelimelerinin sansürlenmesi sonucunda birden fazla token'a ayrıldığını görüyoruz.

03

Unmasked Padding Drift.

Biliyorsunuz ki modellere farklı uzunluklarda sekanslar verilirken bunları padding yöntemiyle aynı uzunluğa getirerek vermek zorundayız. Bunu yaparken pad token'larının model tarafından dikkate alınmaması için attention mask kullanırız. Bu sayede model hangi token'ları dikkate alacağını bilir.

Bu testimizde 5 token'lık bir girdiyi 32 token'a tamamlayarak maskesiz bir biçimde modellere verdik.

Sonuçlara baktığımızda; "Sonuçları inceler".

Üç modelin de bu pad token'larından etkilendiğini görüyoruz. DistilBERT ve RoBERTa modelleri çok etkilenmese de ALBERT modelinin tamamen kör olduğunu söyleyebiliriz. ALBERT modeli girdiden bağımsız olarak hep aynı çıktıyı vermektedir.

ALBERT modeli diğer iki modelden farklı olarak RAM ve hafıza yükünü azaltmak için paylaşımlı ağırlık matrisi yöntemini kullanır. Diğer iki model ise her katmanı için bir ağırlık matrisine sahiptir. Bu ortak kullanımdan dolayı maskelenmemiş pad token'ların sebep olduğu hata her katmanda artarak gürültüye sebep olmakta ve modeli kör etmektedir.

04

Burada modellerimize iki farklı sekans verdik. Birincisi negatif başlayıp pozitif biten, ikincisi pozitif başlayıp negatif biten sekans. Burada negatif başlayp pozitif bir ifade ile biten sekansı modellerimize verdiğimizde hepsinin %90 üzerinde pozitif çıktı verdiğini görüyoruz. Fakat, pozitif başlayıp negatif ifade ile biten bir sekans verdiğimizde özellikle iki modelde belirgin bir güven kaybı görüyoruz.

Final

Okur.