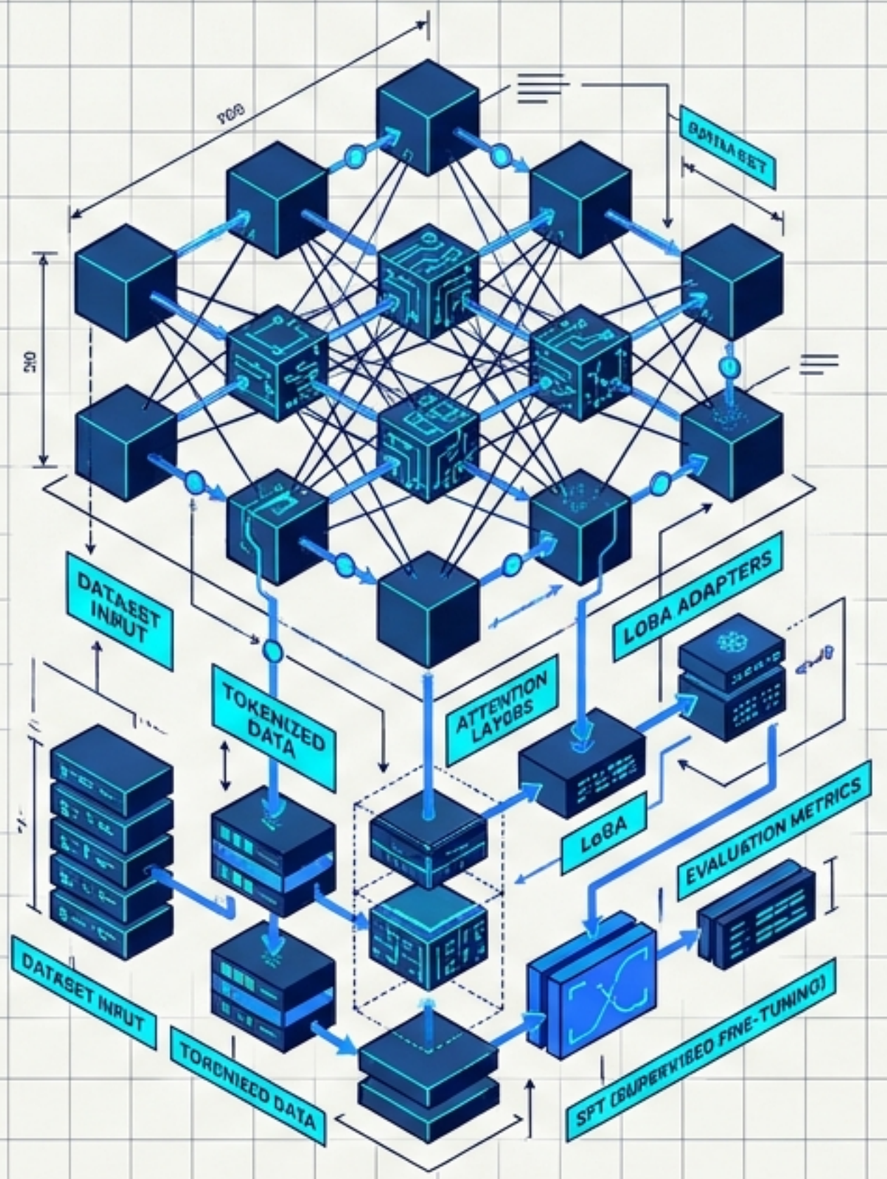
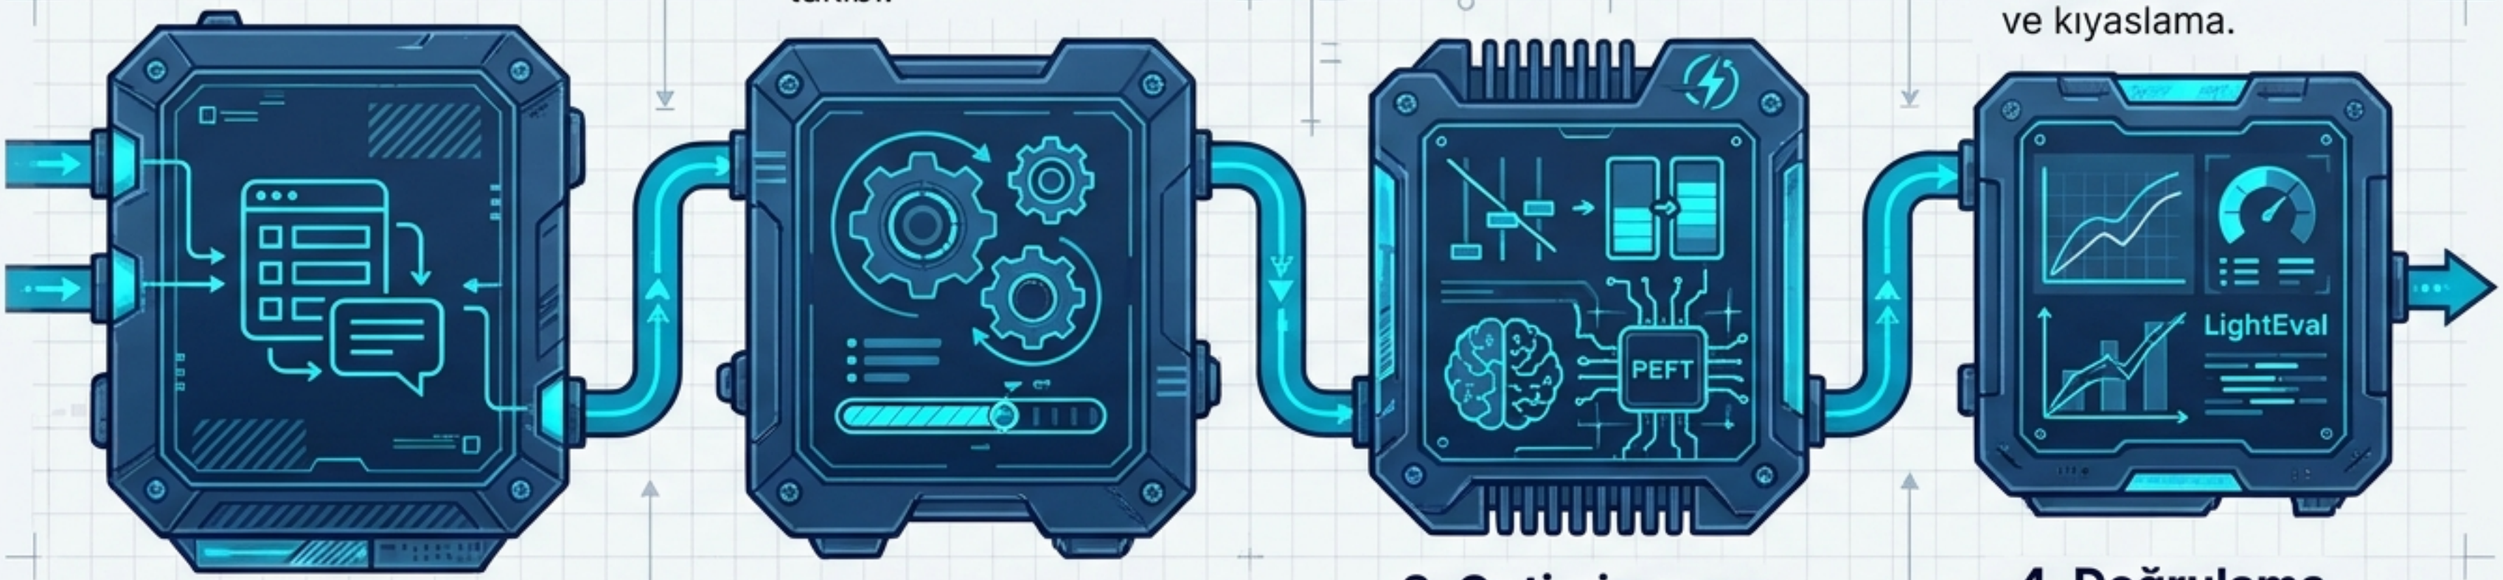
Büyük Dil Modelleri İçin İnce Ayar Rehberi

Hugging Face Ekosistemi ile Uçtan Uca SFT, LoRA ve Değerlendirme Mimarisi



Gemini Notebook

İnce Ayar Yaşam Döngüsü



1. Veri ve Format

Chat Templates: Modeli sohbete hazırlamak.

2. Motor (SFT)

SFTTrainer: Mekanik eğitim ve ilerleme takibi.

2. Motor (SFT)

SFTTrainer: Mekanik eğitim ve ilerleme takibi.

3. Optimizasyon (LoRA)

PEFT: Parametre verimliliği ve bellek tasarrufu.

4. Doğrulama (Evaluation)

LightEval: Gerçek dünya performansı ve kıyaslama.

4. Doğrulama (Evaluation)

LightEval: Gerçek dünya performansı ve kıyaslama.

Gemini Notebook

Temel Model (Base) vs. Talimat Modeli (Instruct)

Base Model

```
The capital of France is
Paris, which is a city
known for its...
```

Yapılandırılmamış ardışık token tahmini.

Instruct Model

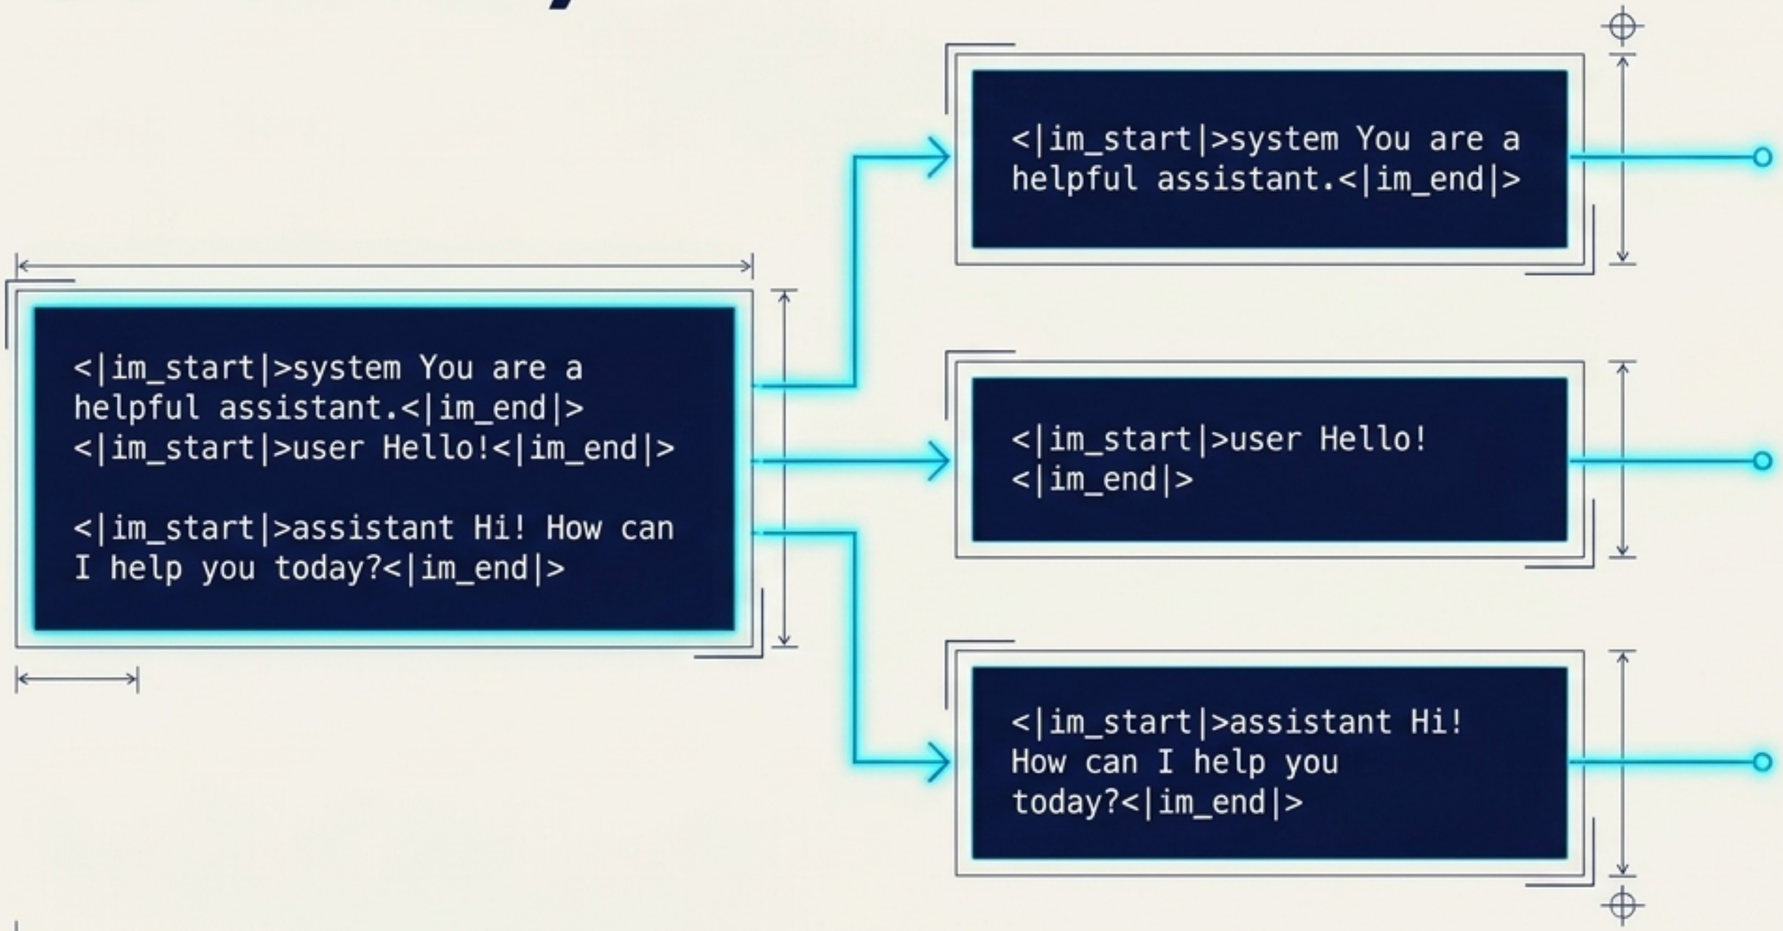


Yapılandırılmış, role dayalı sohbet akışı.

Talimat modelleri, rolleri (kullanıcı, sistem, asistan) tanıyabilmek için tutarlı bir şablon formatına ihtiyaç duyar.

Gemini Notebook

ChatML Anatomisi (Parçalanmış Görünüm)



Sistem Mesajı: Modelin davranışını ve sınırlarını belirler.

Kullanıcı Etiketi: İnsan girdisini izole eder.

Asistan Yanıtı: Modelin üreteceği çıktının başlangıç noktası.

Gemini Notebook

Model Şablonları Karşılaştırma Matrisi

	Llama 2	Llama 3	Mistral	Qwen (ChatML)
Sistem Mesajı	`<<SYS>>`	`<|system|>`	İlk talimata dahil	`<|im_start|>system`
Mesaj Sınırları	`[INST]` / `[/INST]`	Role özel etiketler	`[INST]` / `[/INST]`	Role özel etiketler
Özel Tokenlar	<s> ve </s>	Sonda </s>	<s> ve </s>	Role özel tokenlar



Yanlış şablon kullanımı performans düşüklüğüne yol açar. Her zaman Hub'daki `tokenizer_config` kontrol edilmelidir.

Gemini Notebook

Gelişmiş Şablon Yetenekleri

Gelişmiş Şablonlar

Araç Kullanımı (Tool Use)

```
tool_calls: [{
  "tool": "weather_api",
  "parameters": {"city": "Paris"}}
]
```



Çok Modlu Girdiler (Multimodal)

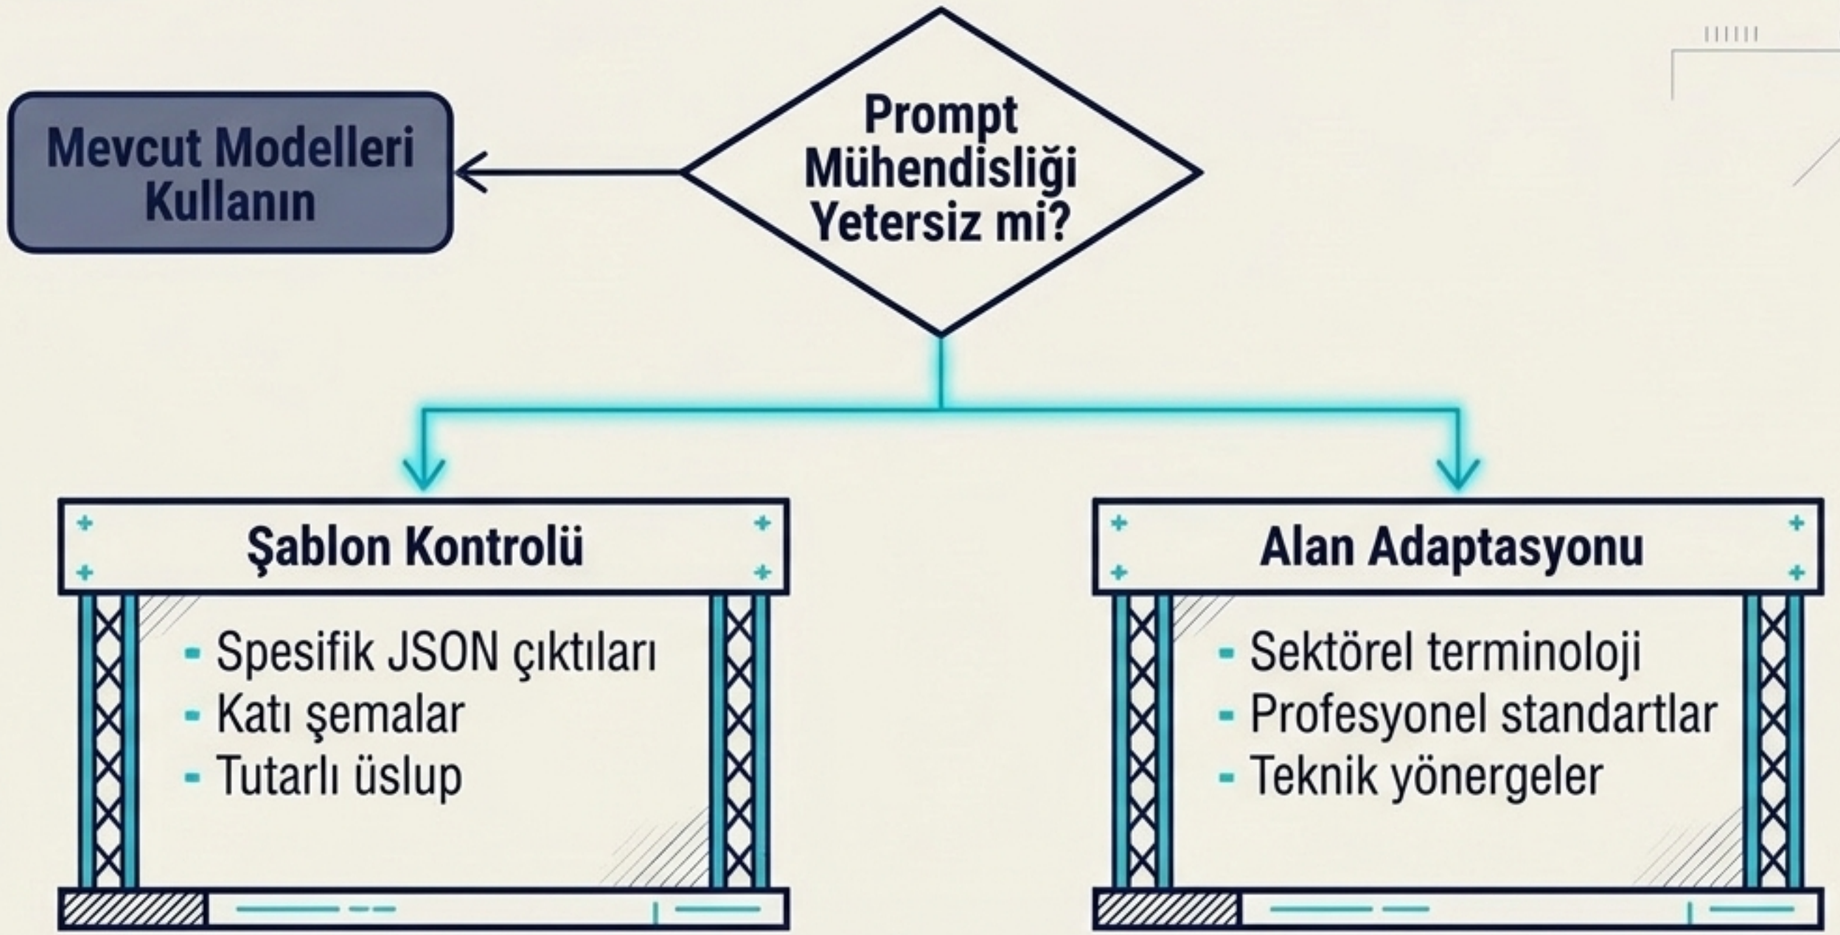
```
[{"type": "text"},
  {"type": "image",
   "image_url": "..."}
}]
```



En İyi Uygulama: Token limitlerine dikkat edin ve mesaj yapısını modele göndermeden önce mutlaka doğrulayın.

Gemini Notebook

Karar Ağacı: SFT Ne Zaman Gerekli?



Uyarı: SFT yüksek donanım ve mühendislik eforu gerektirir. Sadece ek performansa ihtiyaç duyulduğunda tercih edilmelidir.

Gemini Notebook

SFT Motorunun Yapılandırılması (TRL)

Veri Paketleme: Optimizasyon için kısa dizileri birleştirir.

```
from trl import SFTConfig, SFTTrainer

training_args = SFTConfig(
    max_steps=1000,
    per_device_train_batch_size=4,
    learning_rate=5e-5,
    packing=True
)
```

Eğitim Süresi: Epoch yerine alternatif. Yüksek değerler daha iyi öğrenme sağlar ancak aşırı uyum (overfitting) riskini artırır.

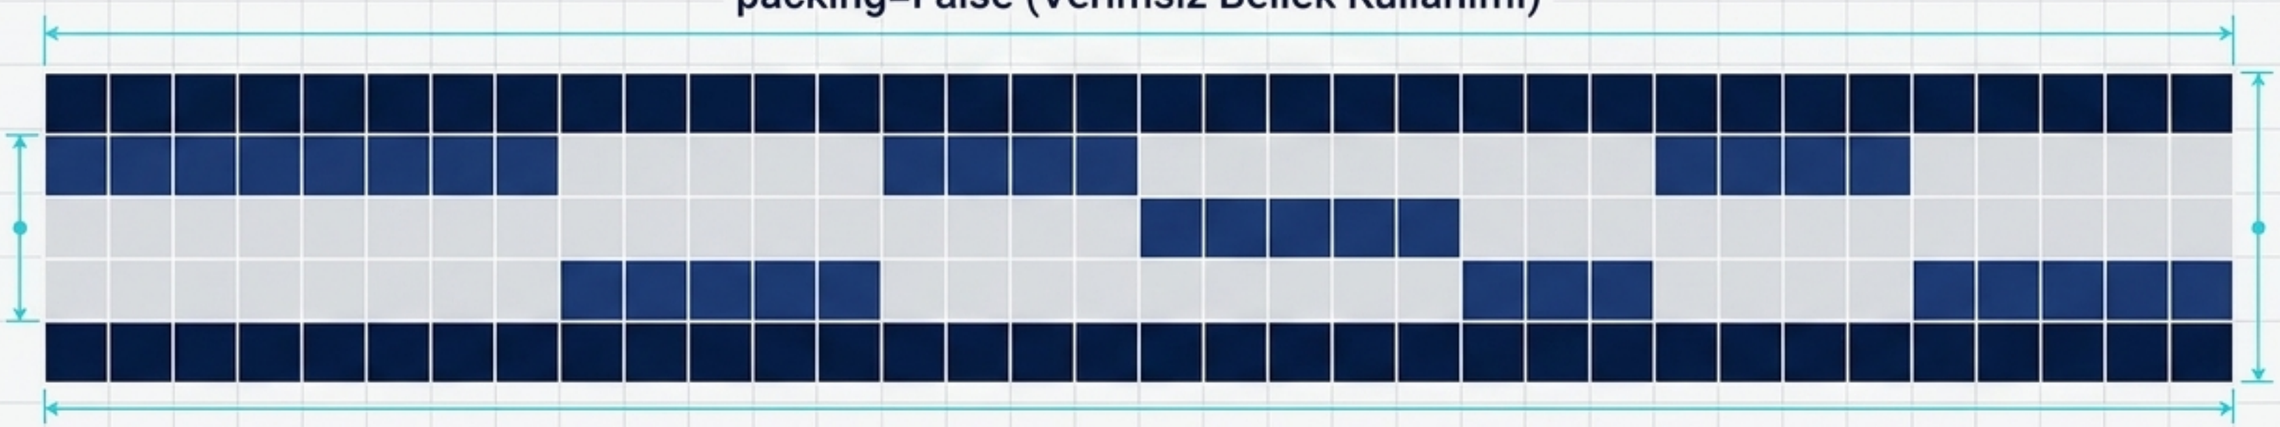
Öğrenme Oranı: **Öğrenme Oranı:** Ağırlık güncellemelerinin boyutunu kontrol eder.

Bellek ve Stabilite: GPU bellek kullanımını belirler.

Gemini Notebook

Veri Paketleme (Dataset Packing) Şeması

packing=False (Verimsiz Bellek Kullanımı)



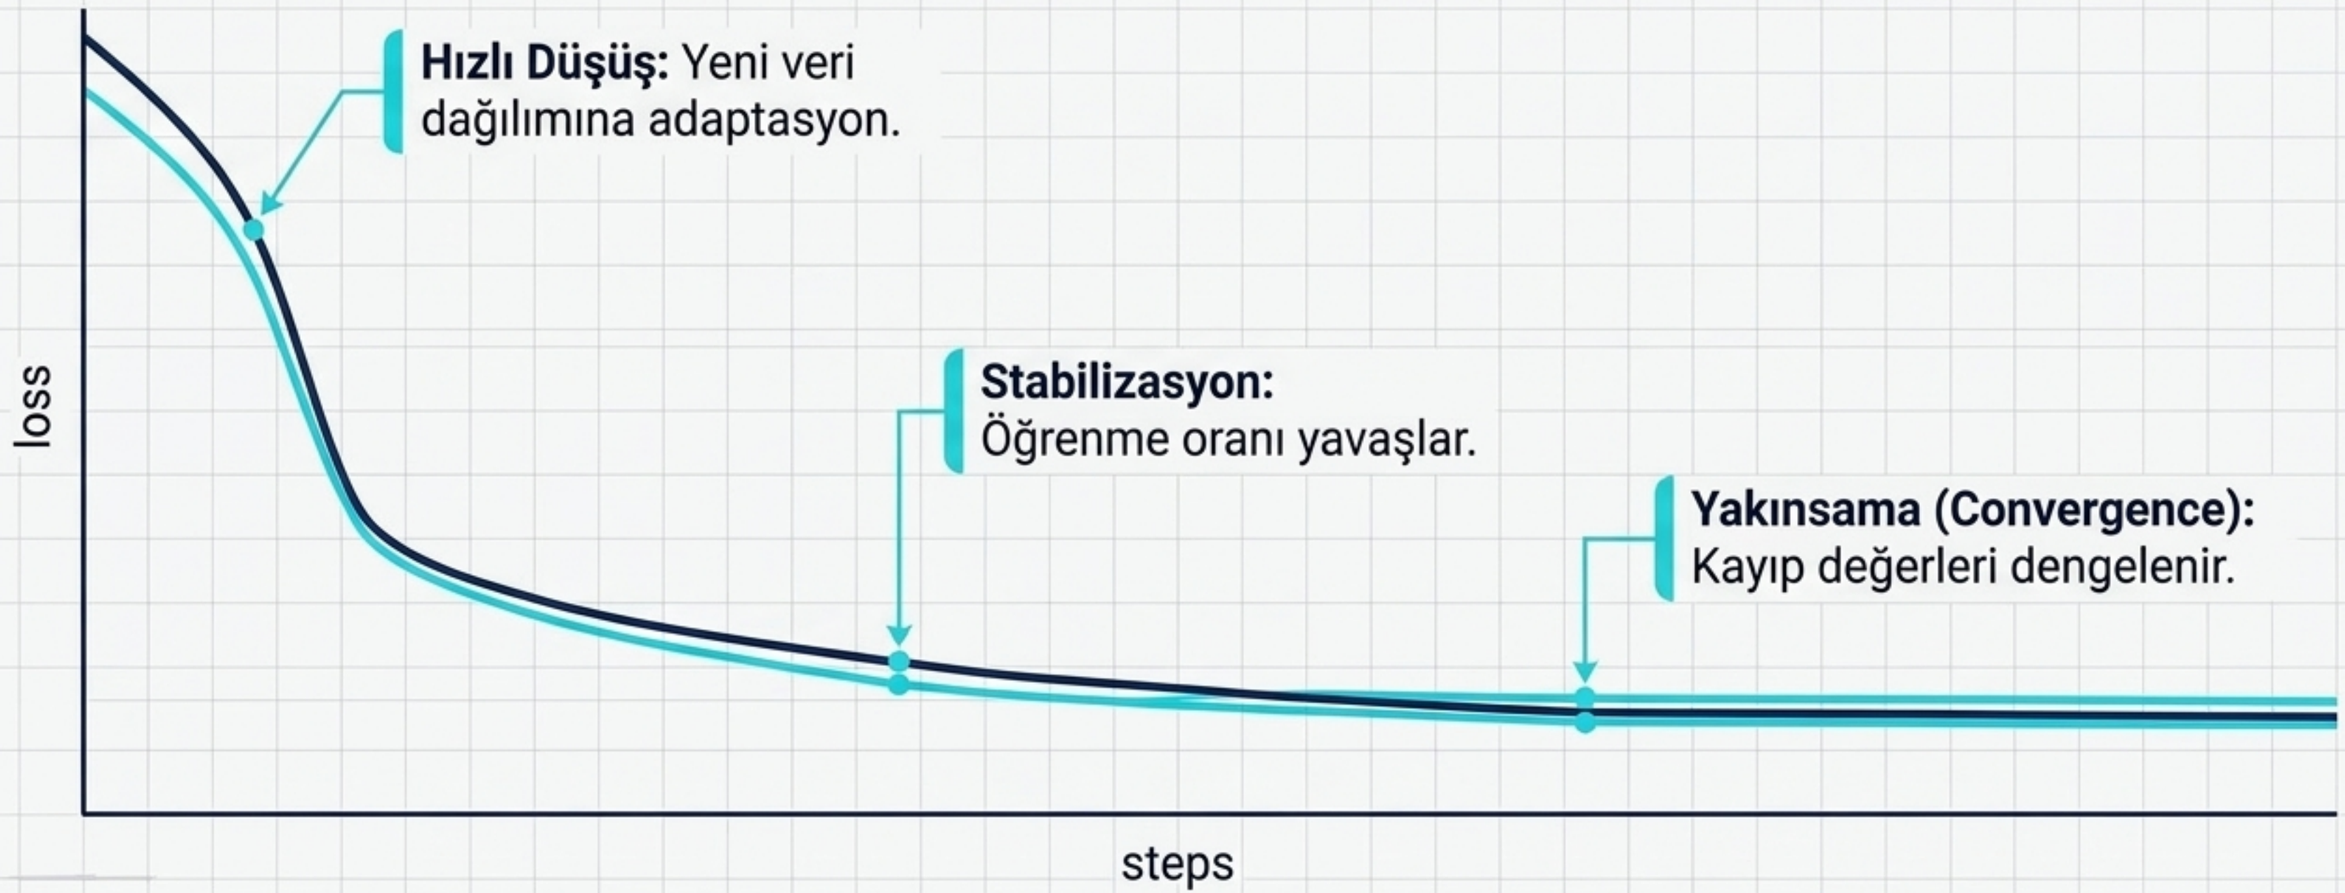
packing=True (Maksimum Verimlilik)



Kısa örnekleri aynı girdi dizisinde birleştirerek GPU kullanımını maksimize eder.
SFTConfig(packing=True) ile aktif edilir.

Gemini Notebook

Tanı Panosu: Sağlıklı Yakınsama (Convergence)

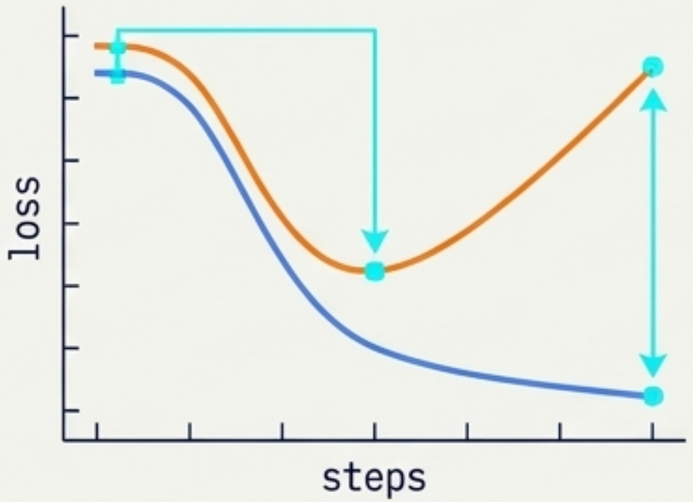


Eğitim ve doğrulama kaybı arasındaki küçük boşluk, modelin ezberlemek yerine genellenebilir örüntüler öğrendiğini gösterir.

Gemini Notebook

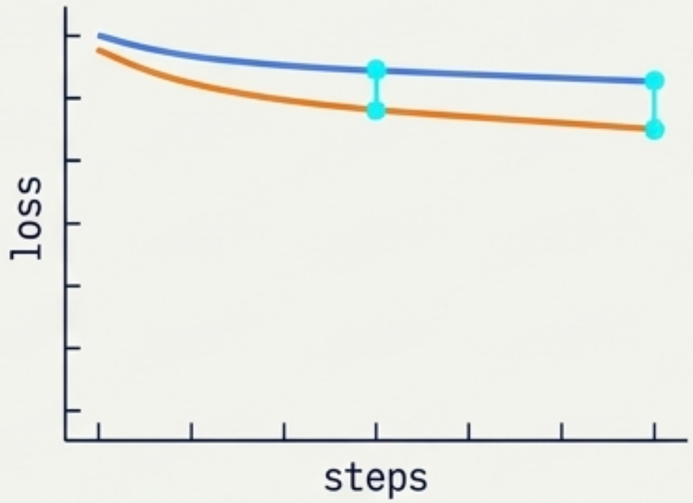
Tanı Panosu: Uyarı İşaretleri ve Çözümler

Aşırı Uyum (Overfitting)



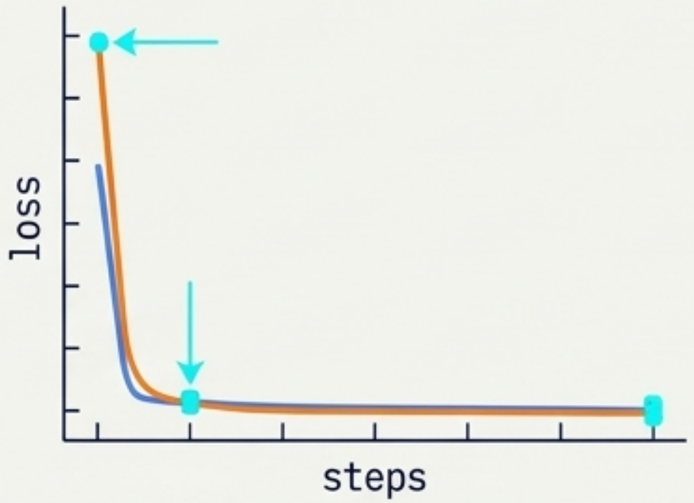
- **Sorun**: Doğrulama kaybı artarken eğitim kaybı düşüyor.
- **Çözüm**: Eğitim adımlarını azaltın, veri kümesini büyütün.

Yetersiz Uyum (Underfitting)



- **Sorun**: Kayıplarda anlamlı bir düşüş yok.
- **Çözüm**: Öğrenme oranını (learning rate) artırın.

Ezberleme (Memorization)



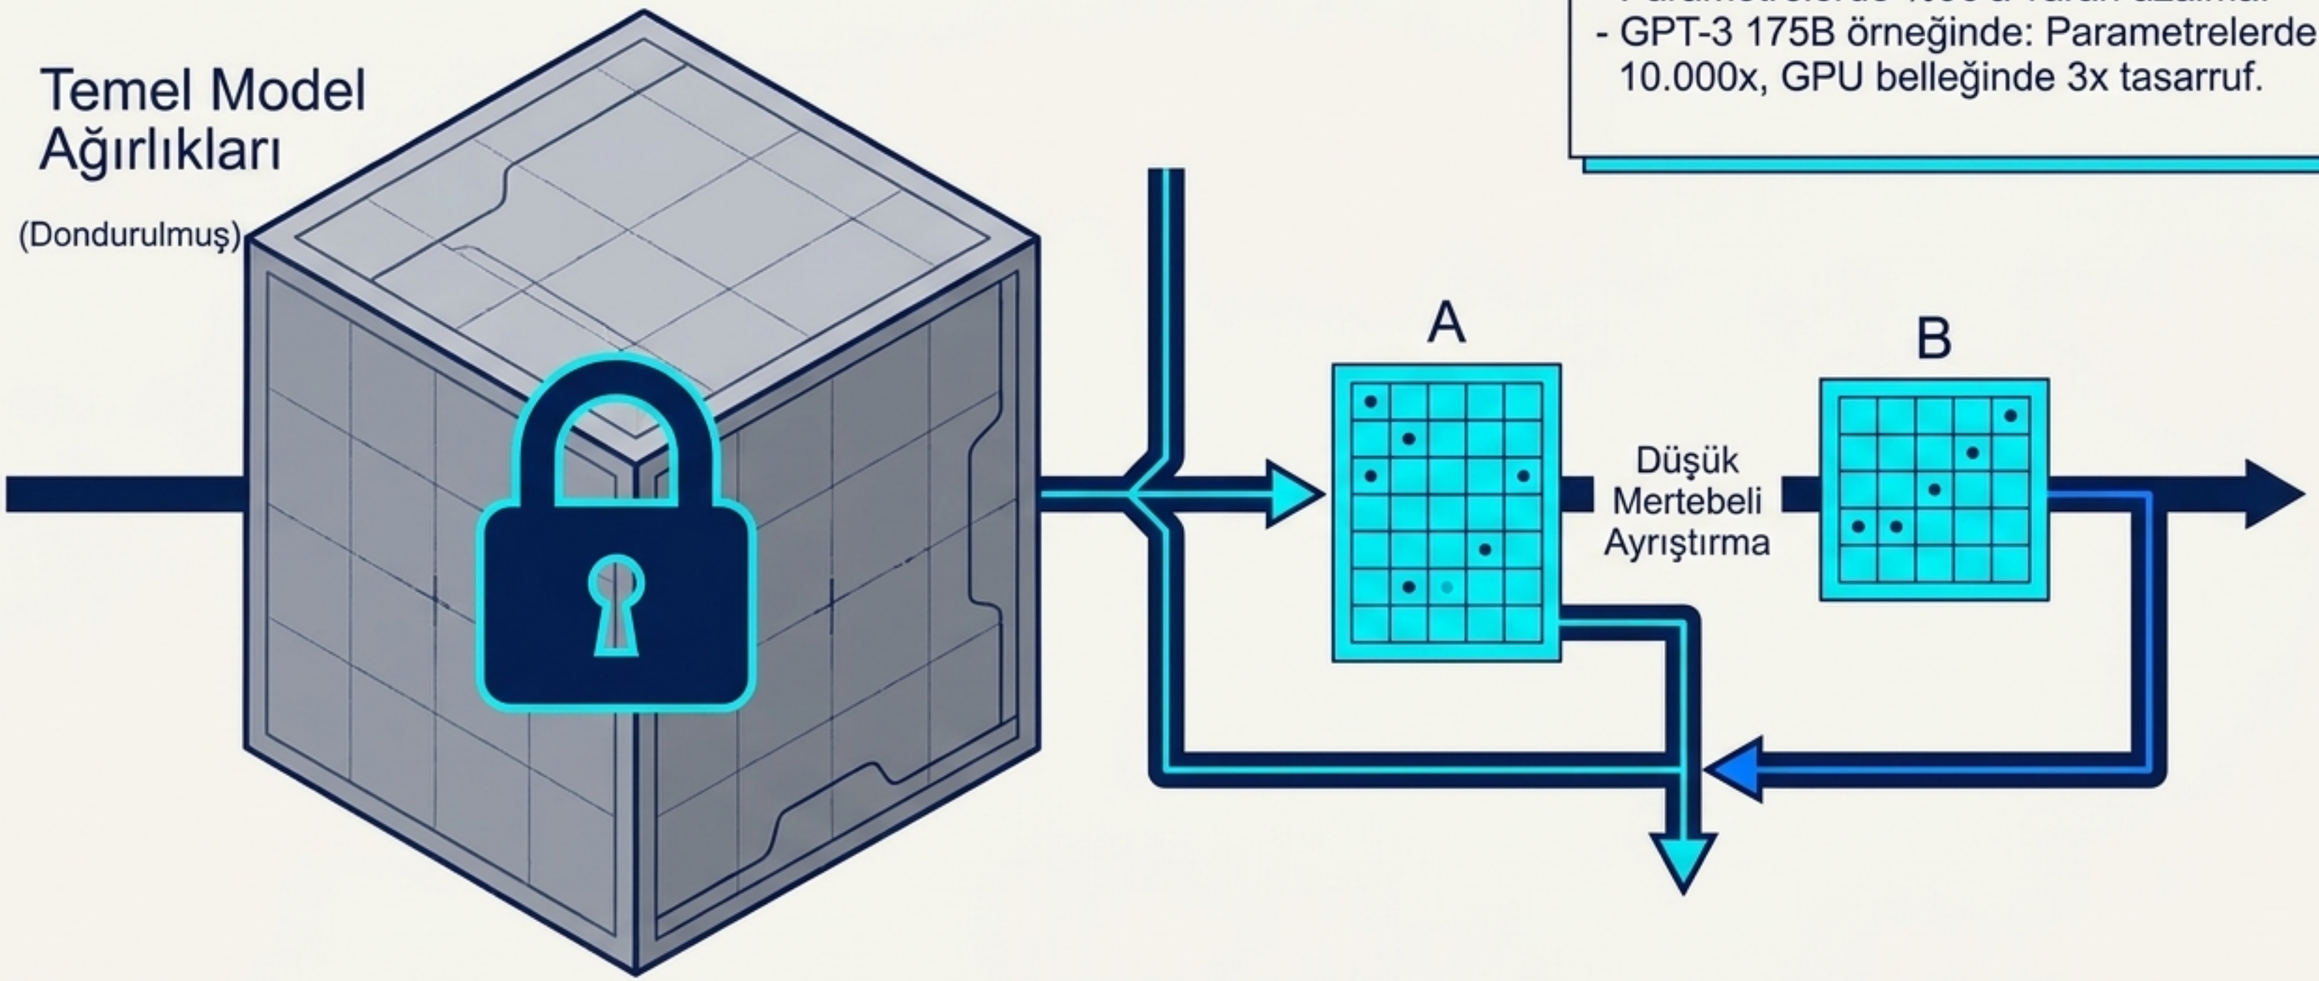
- **Sorun**: Aşırı düşük kayıp değerleri. Yeni verilerde kötü performans.
- **Çözüm**: Model çıktılarını kalitatif olarak inceleyin, veri çeşitliliğini artırın.

Gemini Notebook

LoRA Mekanizması (Düşük Mertebeli Adaptasyon)

Performans Metrikleri:

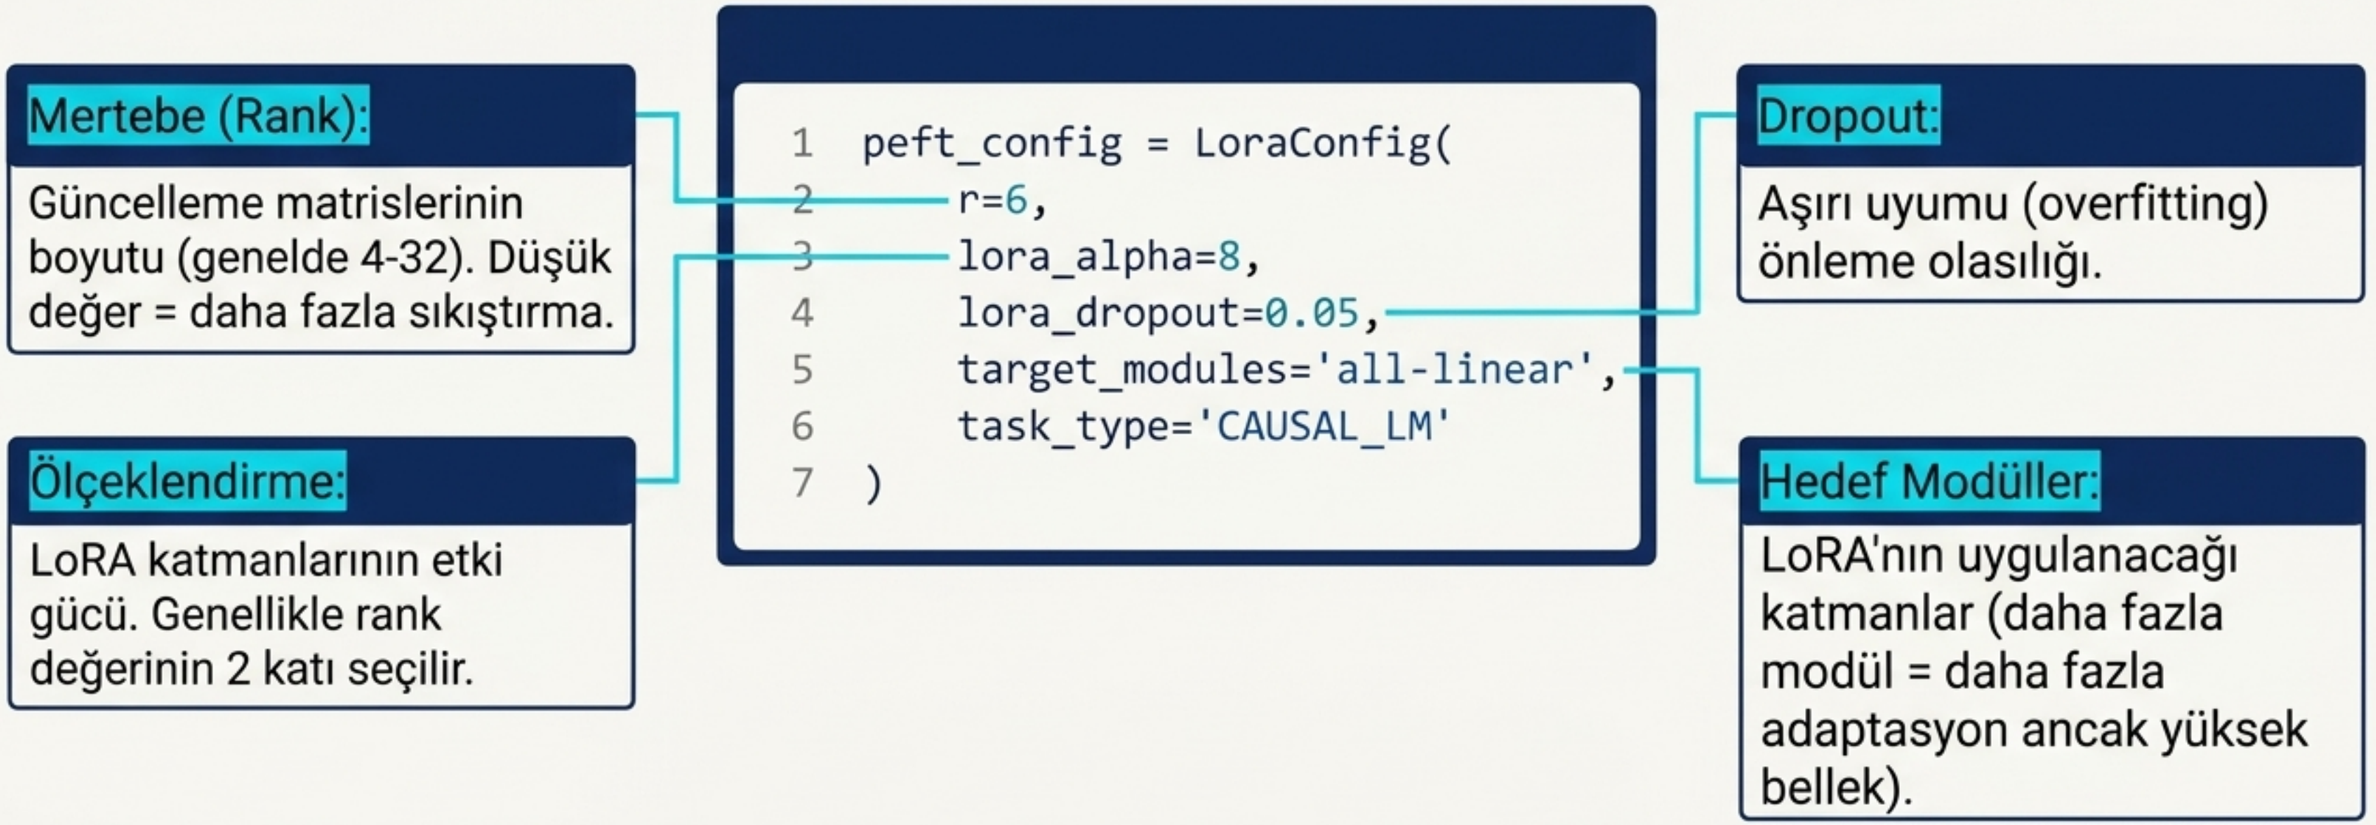
- Parametrelerde %90'a varan azalma.
- GPT-3 175B örneğinde: Parametrelerde 10.000x, GPU belleğinde 3x tasarruf.



Modelin tüm ağırlıklarını eğitmek yerine, ağırlık güncellemelerini daha küçük matrislere ayrıştırarak (**low-rank decomposition**) belleği korur.

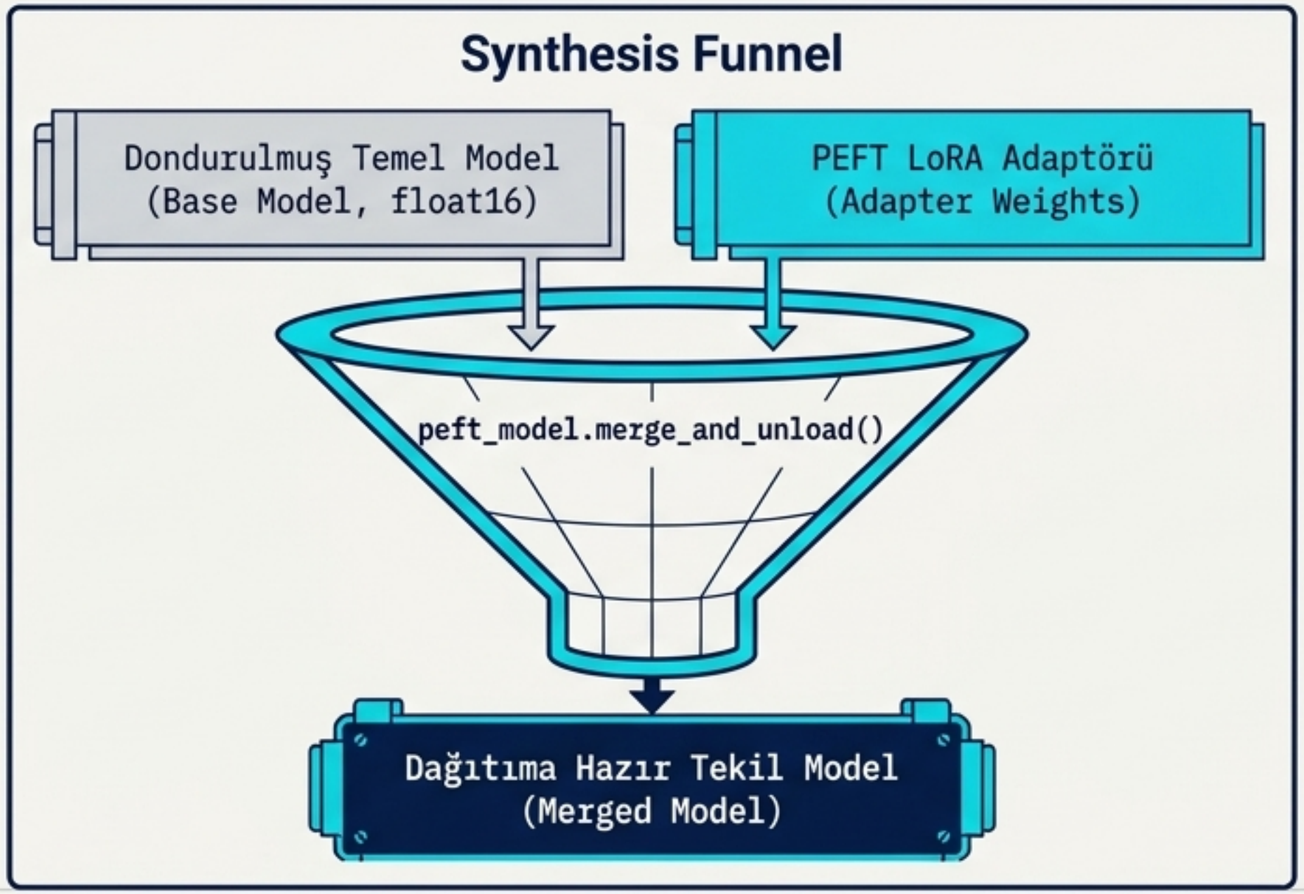
Gemini Notebook

LoRA Konfigürasyon Mimarisi



Gemini Notebook

Adaptörleri Birleştirme (Merging Adapters)



Uyarı: Birleştirme işlemi sırasında CPU/GPU belleğine dikkat edin ve eğitimdeki hassasiyeti (torch_dtype) koruyun. Tokenizer'ı da modelle birlikte kaydetmeyi unutmayın.

Gemini Notebook

Otomatik Kıyaslama (Benchmark) Taksonomisi

KATEGORİ	BENCHMARK DETAYLARI
1. Genel Bilgi	• MMLU (57 farklı konu, geniş kapsamlı)
2. Akıl Yürütme (Reasoning)	• BBH (Mantıksal düşünme ve planlama) • GSM8K (Matematiksel problem çözme)
3. Matematik & Kod	• MATH (Çok adımlı çözümler, formel notasyon) • HumanEval (Python kod üretimi ve fonksiyonel test)
4. Güvenlik ve Doğruluk	• TruthfulQA (Yanlış bilinen gerçekleri üretme eğilimi)
5. Talimat Takibi	• Alpaca Eval (GPT-4 hakemliği ile yardımseverlik/zararsızlık ölçümü)

Gemini Notebook

Alternatif Değerlendirme Yaklaşımları

LLM-as-Judge (Hakem Olarak LLM)



- **Kavram:** Bir dil modelinin çıktısını değerlendirmek için başka bir model (örn. GPT-4) kullanmak.
- **Avantaj:** Geleneksel metriklerden daha incelikli geri bildirim sağlar.

Evaluation Arenas (Chatbot Arena)



- **Kavram:** Kitle kaynaklı geri bildirim. İki model arasında anonim savaşlar ve kullanıcı oylaması.
- **Avantaj:** Gerçek dünya kullanım kalıplarını ve insan tercihlerini yansıtır.

Gemini Notebook

Kapsamlı Değerlendirme Stratejisi

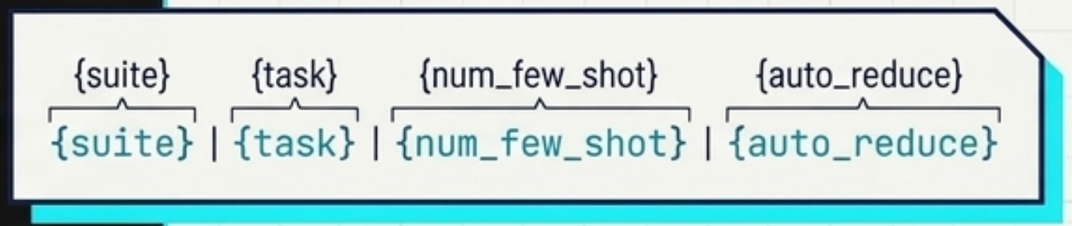


Kritik İçgörü: Sadece akademik kıyaslamalardaki başarı, gerçek dünya etkinliğine doğrudan yansımaz. Çok katmanlı test şarttır.

Gemini Notebook

LightEval ile Otomatik Değerlendirme

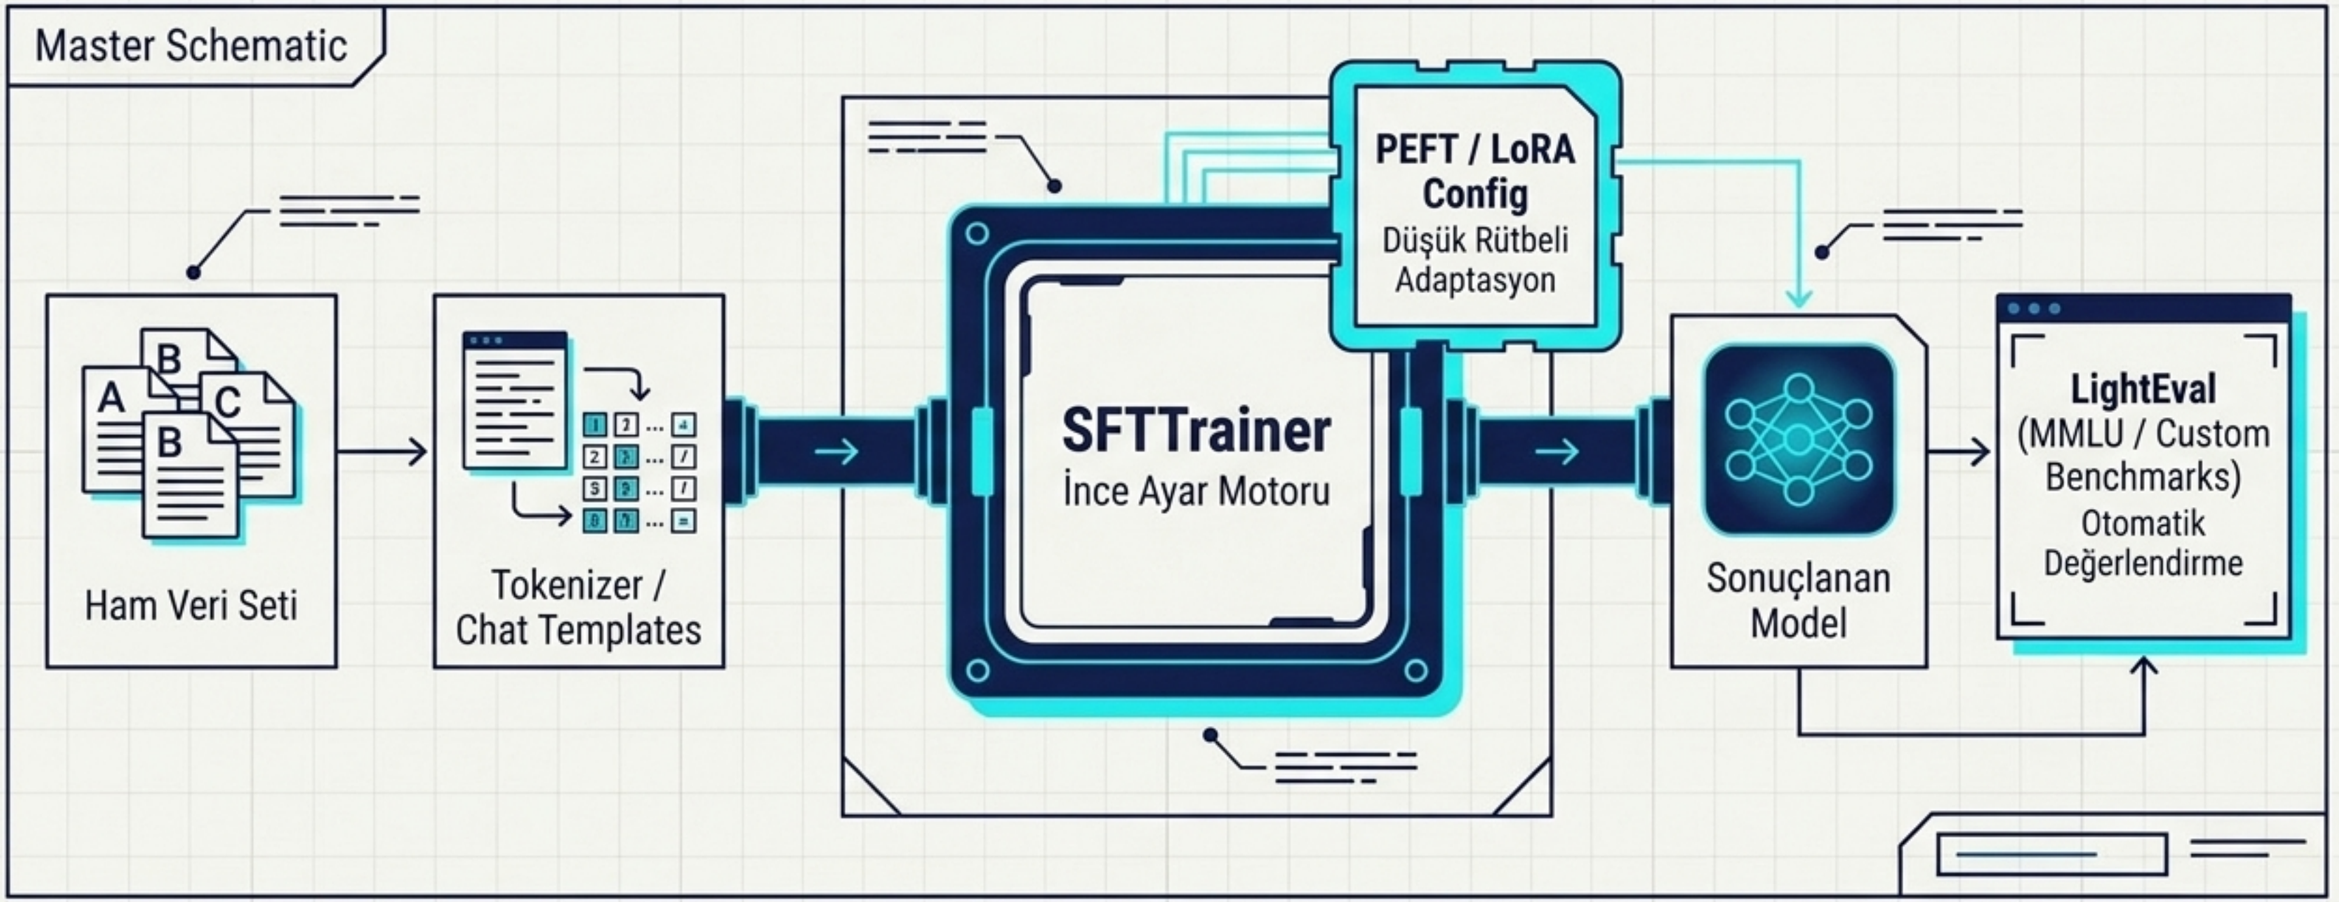
```
lighteval accelerate \
  'pretrained=your-model-name' \
  'mmlu|professional_medicine|0|0' \
  --save_generations true
```



Task	Version	Metric	Value
anatomy	0	acc	0.4500
high_school_biology	0	acc	0.1500

Gemini Notebook

Uçtan Uca İnce Ayar Ekosistemi



Bu araçlar yalıtılmış sistemler değil; veri hazırlığından doğrulamaya kadar sorunsuz çalışan tek bir entegre motordur.

Gemini Notebook

Sonuç ve Ana Çıktılar

✅ [VERİ]: Sohbet Şablonları (Chat Templates) ile etkileşimleri yapılandırdık.

✅ [EĞİTİM]: SFT ile temel modelleri spesifik görevlere adapte ettik.

✅ [VERİMLİLİK]: LoRA ile bellek gereksinimlerini optimize ederek büyük modelleri eğitilebilir kıldık.

✅ [ÖLÇÜM]: Hem standart hem de özel değerlendirme stratejileriyle performansı doğruladık.

Hugging Face (TRL, PEFT, LightEval) ekosistemi, hesaplama açısından verimli, sektöre özel ve yüksek performanslı yapay zeka asistanları inşa etmek için uçtan uca eksiksiz bir mimari sunar.

Gemini Notebook